



저작자표시-비영리-변경금지 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.

다음과 같은 조건을 따라야 합니다:



저작자표시. 귀하는 원저작자를 표시하여야 합니다.



비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.



변경금지. 귀하는 이 저작물을 개작, 변형 또는 가공할 수 없습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 [이용허락규약\(Legal Code\)](#)을 이해하기 쉽게 요약한 것입니다.

[Disclaimer](#)

스마트 팩토리용 설비 예지보전 모델의 분석 및 제언

연세대학교 공학대학원

산업정보경영 전공

강 성 우

스마트 팩토리용 설비 예지보전 모델의 분석 및 제언

지도교수 김 창 욱

이 논문을 석사학위 논문으로 제출함

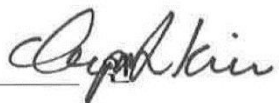
2018 년 12 월 일


연세대학교 공학대학원

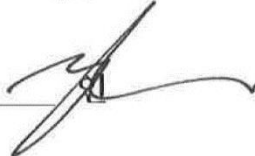
산업정보경영 전공

강 성 우

강성우의 석사학위논문을 인준함

심사위원 김 창 욱 

심사위원 정 병 도 

심사위원 모 정 훈 

연세대학교 공학대학원

2018 년 12 월 일

감사의 글

새로운 지식을 습득하는 것은 언제나 제 삶의 원동력이 됨을 다시 한번 느낄 수 있었습니다. 이 새로 습득한 지식이 앞으로의 경험과 만나, 저를 다시 새로운 세계로 안내하리라 기대합니다.

부족한 지식과 생각을 채우는 데 많은 지도를 해주신 김창욱 교수님께 진심으로 감사 드리며, 더불어 저의 논문에 관심 가져주시고 가르침을 아끼지 않으신 모정훈 교수님, 정병도 교수님께도 감사 드립니다.

또한, 논문 작성에 조언과 격려를 아끼지 않으신 창세기랩 선, 후배님들과 장찬희 박사님께도 감사 드립니다.

그리고 지난 5 학기 함께하며 서로를 지지해 준 91 기 동기들께도 감사합니다. 여러분들이 있어 앞으로의 인생이 벌써 풍요로워진 느낌 입니다.

마음속에 큰 버팀목이 되어 주는 저와 아내의 모든 친척분들과 장모님, 하늘에 계신 장인 어른께 감사 드립니다.

그리고 저를 사랑으로 키워주신 부모님 감사 드립니다. 부모님으로부터 건강한 사고를 배웠기에 지금의 제가 있을 수 있습니다.

마지막으로 항상 제게 힘이 되어 주는 사랑하는 아내 기은영, 아들 강민재에게 진심으로 감사 드리며, 이 작은 결실의 기쁨을 함께 하고 싶습니다.

2018 년 12 월

강 성 우

목 차

목 차	i
그림차례	iii
표 차 례	iv
국문요약	v

제 1 장 서론

1.1 연구 배경	1
1.2 연구 목적과 의의	2

제 2 장 이론적 배경

2.1 스마트 팩토리	
2.1.1 스마트 팩토리 및 그 주요기술	4
2.1.2 스마트 팩토리의 통합 요소	6
2.1.3 스마트 팩토리의 글로벌 트렌드	9
2.2 설비 예지보전	
2.2.1 설비종합효율	11
2.2.2 예지보전의 정의	15
2.2.3 설비 고장 진단과 예지 방법론	18

제 3 장 설비 예지보전 모델에 대한 연구

3.1 연구 모형	22
3.2 문헌 고찰	
3.2.1 설비 고장 진단과 예지 방법론 별 분류	24
3.2.2 설비 고장 진단과 예지 대상 별 분류	28
3.2.3 설비 고장 진단과 예지 관련 선행 연구 분류	30
3.3 과제 도출	32
3.4 연구 방향 제언 및 실험	
3.4.1 연구 방향 제언	33
3.4.2 실험 개요	35
3.4.3 데이터 취득 및 결과	38

제 4 장 결론

4.1 연구 결론	42
4.2 연구의 한계	43

참고 문헌	45
-------------	----

[ABSTRACT]	52
------------------	----

그림 차례

그림 1. The 4th Industrial Revolutions.....	5
그림 2. The Smart factory of the future	6
그림 3. Horizontal Integration and Vertical Integration.....	9
그림 4. 세계 주요국의 스마트 팩토리 방향 및 정책.....	10
그림 5. Maintenance strategy continuum	14
그림 6. 예지보전 절차.....	18
그림 7. Classification of FDD methods.....	20
그림 8. 연구 모형	22
그림 9. 선행 연구 분류도.....	23
그림 10. 진단, 예지 대상 별 연구 비중.....	29
그림 11. 테스트 베드 구성.....	36
그림 12. 데이터 취득 예시.....	39
그림 13. Universal robots 의 관절 구성.....	40

표 차 례

표 1. 진단과 예지의 방법 분류 및 특징	19
표 2. 선행연구 분류표	30-31
표 3. 협업로봇에서 취득한 데이터	37
표 4. 가공 데이터 예시	40

국문요약

스마트 팩토리용 설비 예지보전 모델의 분석 및 제언

연세대학교 공학대학원

산업정보경영전공

강 성 우

전 세계적으로 많은 국가들이 자국의 제조업 경쟁력 향상을 위한 목적으로 스마트 팩토리에 대한 관심 및 정책적인 지원이 증가하고 있다. 기존 제조 공장들이 스마트 팩토리로 전환을 통해 얻고자 하는 것은 다품종 대량생산, 품질향상, 생산이력 데이터의 디지털 관리 등 여러 가지가 있지만, 공통적인 목적은 이를 통해 생산성 및 제조 경쟁력을 향상시키는 것에 있다.

생산성 및 제조 경쟁력을 높이기 위해 각 기업에서는 고가의 스마트 설비 도입을 검토하고 있으나, 이들 설비의 도입은 구입 및 설치 비용 외에도 유지보수를 위한 비용이 많이 소모되며, 고장으로 인해 생산 라인이 정지되는 경우 생산성에 큰 악영향을 미치게 되는 등의 요인으로 인해 도입이 쉽지 않은 실정이다.

이에 공장의 설비종합효율(OEE, Overall Equipment Effectiveness)을 높이기 위한 방법으로, 설비의 데이터를 분석하여 이상징후를 사전에

파악하고 조치하는 예지보전(PdM, Predictive Maintenance)이 스마트 팩토리의 주요 기능으로 관심을 받고 있다.

설비 예지보전과 관련된 연구들은 과거에도 많이 제시되었지만, 설비의 상태 정보를 파악할 환경이 제대로 마련되어 있지 않아 많은 제한이 있었으며, 명확한 방향 제시 없이 다양한 사례연구 위주로 진행되어 왔다.

본 연구에서는 설비 예지보전과 관련된 스마트 팩토리 기술 수준을 분석하고, 43 건의 기존 사례 연구 문헌의 고찰을 통해 향후 스마트 팩토리 환경에서의 설비의 고장 진단, 예지에 대한 연구 방향으로 Data-driven approach 방법론을 활용한 예지보전, 어플리케이션 레벨의 예지보전, 의사결정을 위한 최적 데이터 유형 및 규모 연구, 예지보전 대상 선정 연구를 제안하였다.

또한, 실제 스마트 팩토리 환경에서 설비의 예지보전에 활용이 가능한 데이터를 수집하는 실험을 통해 제안 내용에 대한 활용 가능성을 검증하였고, 이 과정에서 고장항목의 정의 및 체계적인 고장 데이터의 관리가 설비의 예지보전에 무엇보다 중요하다는 것을 알 수 있었다.

본 연구의 제언을 바탕으로 스마트 팩토리 환경에서 설비 예지보전 모델의 연구가 진행되기를 기대한다.

핵심되는 말 : 스마트 팩토리, 예지보전, 설비종합효율, Smart factory, Predictive maintenance, Condition based maintenance, Overall Equipment Effectiveness, Data-driven approach, Model-based algorithm

제 1 장 서론

1.1 연구 배경

전 세계적으로 재료비, 인건비 등 제조원가가 상승하는 사회적 상황에서 자국의 제조경쟁력을 유지시키기 위해 각 국가에서는 자국 산업 특성에 맞는 다양한 정책들을 펼치고 있으며, 빠르게 변화하는 소비자들의 기호 및 점점 짧아지고 있는 제품의 생명주기, 급격한 수요 변동에 대응하기 위해 많은 제조 기업들은 각각의 제조 혁신 활동을 펼치고 있다. 이러한 변화하는 제조업의 환경에서 최근에는 Digitalization 이라는 최신 Technical trend 의 다양한 기술을 활용한 스마트 팩토리가 주목을 받고 있다.

기존 제조 공장들이 스마트 팩토리로의 전환을 통해 얻고자 하는 것은 다품종 대량생산을 통한 소비자들의 기호 충족, 품질향상, 생산이력 데이터의 디지털 관리 등 여러 가지 목표이 있지만, 공통적인 목적은 생산성 및 제조 경쟁력을 향상시키는 것에 있다.

생산성 및 제조 경쟁력을 높이기 위해 각 기업에서는 고가의 스마트 설비 도입을 검토하고 있으나, 이들 설비의 도입은 구입 및 설치 비용 외에도 유지보수를 위한 비용이 많이 소요되며, 고장으로 인해 생산 라인이 정지되는

경우 생산성에 큰 악영향을 미치게 되는 등의 요인으로 인해 도입이 쉽지 않은 실정이다.

이에 설비의 가용성, 성능, 품질의 종합적인 평가를 통해 생산성을 나타내는데 사용되는 지표인 설비종합효율 (OEE, Overall Equipment Effectiveness)을 높이기 위한 방법으로, 설비의 데이터를 분석하여 이상징후를 사전에 파악하고 조치하는 예지보전(PdM, Predictive Maintenance)이 스마트 팩토리의 주요 기능으로 관심을 받고 있다.

1.2 연구 목적과 의의

설비 예지보전과 관련된 연구들은 과거에도 많이 제시되었지만, 설비의 상태 정보를 파악하기 위한 데이터의 취득 및 저장과 관련된 환경이 제대로 마련되어 있지 않았던 이유로 연구에 제한이 있었으며, 명확한 방향 제시 없이 다양한 분야에서 각각의 사례연구가 진행되어 왔다.

스마트 팩토리라는 변화하는 제조업의 환경에서 효과적인 예지보전 모델을 선정하기 위해 설비 예지보전과 관련된 스마트 팩토리 기술 수준을 분석하고, 설비 고장 진단과 예지에 사용된 방법론에 대해 알아 보고자 한다.

또한, 기존 사례 연구 문헌의 고찰을 통해 각각의 연구를 설비 고장 진단과 예지에 사용된 방법론과 그 대상에 대해 분석 및 분류를 하여, 과제를 도출하고자 하며, 이를 통해 향후 스마트 팩토리 환경에서의 설비 예지보전과 관련된 연구 방향을 제언하는 것에 목적이 있다.

마지막으로 설비의 예지보전에 활용이 가능한 데이터를 실제 스마트 팩토리 환경에서 수집하는 실험을 통해 본 연구를 통해 제언한 내용에 대한 활용 가능성을 검증해 보고자 한다.

제 2 장 이론적 배경

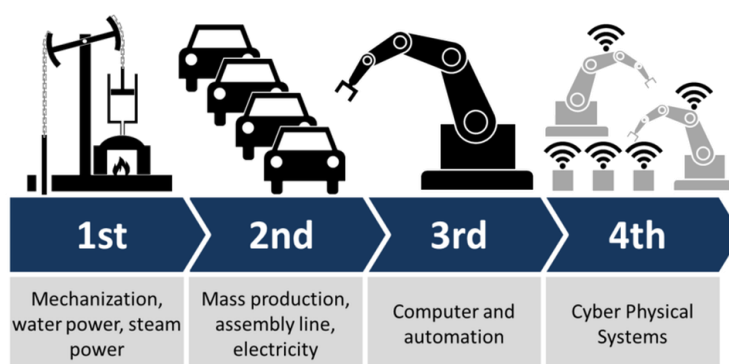
2.1 스마트 팩토리

2.1.1 스마트 팩토리 및 그 주요기술

스마트 팩토리의 등장 배경에는 2016 년 ‘다보스 세계경제포럼(World Economic Forum, WEF)’ 에서 처음 등장한 4 차 산업혁명이 있다.

2016 년 1 월 스위스 다보스에서 개최된 WEF 의 의제는 ‘4 차 산업혁명의 이해(Mastering the Fourth Industrial Revolution)’ 이었다. 이 포럼에서 4 차 산업혁명은 글로벌 위기에 직면한 글로벌 경제를 살릴 수 있는 대안으로 등장하였으며, CPS(Cyber Physical System)으로 통칭되는 물리적, 디지털 및 생물학 영역의 경계를 모호하게 만드는 기술의 융합을 특징으로 한다. 로봇공학(Robotics), 인공 지능(Artificial intelligence), 나노 기술(Nanotechnology), 양자 컴퓨팅(Quantum computing), 생명 공학(Biotechnology), 사물 인터넷(Internet of Things, IoT), 5 세대 무선 기술(5G), 3D Printing, 완전자율주행 자동차 등 다양한 분야에서 새로운 기술 혁신이 나타나고 있다.

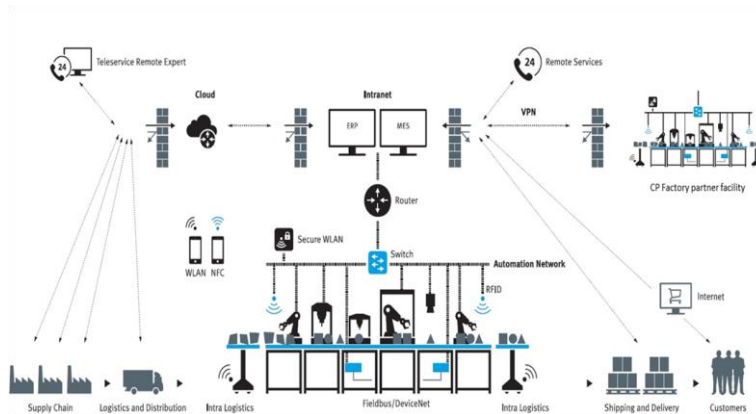
이러한 기술들을 통해 정보기술과 자동화 기술을 연결하여 ‘초연결(hyper-connectivity), 초지능화(super-intelligence)’를 가능하게 하며, 서로 연결된 자원으로부터 수집된 정보를 분석하여 스스로 의사결정을 할 수 있게 되어 사물 간의 정보 교류를 통한 제어가 가능하게 한다[1].



[그림 1] The 4th Industrial Revolutions¹⁾

스마트 팩토리는 초연결, 초지능화를 통해 제조업에서 활용되는 소프트웨어인 IT(Information Technology) Infra 와 제조설비 등과 같은 OT(Operation Technology) Infra 를 Digitalization 기술을 통해 데이터로 연결하여 생산성을 향상시키는 새로운 형태의 제조공장으로 정의할 수 있다. 이러한 새로운 형태의 제조 공장에서는 제품의 개발, 제조, 유통 등의 전 과정을 데이터로 연결하여, 각각의 단계에서 필요한 정보를 쉽게 취득할 수 있게 된다[그림 2].

1) <https://www.allaboutlean.com/>



[그림 2] The Smart factory of the future²⁾

스마트 팩토리의 핵심 기술은 환경 및 공정에 따라 다양하게 선정할 수 있으나, 그 중 대표적인 것이 CPS, IoT, Cloud, Big data, Mobile, AR/VR, AI, 협업로봇 등이 있다.

2.1.2 스마트 팩토리의 통합 요소

스마트 팩토리의 초연결, 초지능화를 구현하기 위해 3 가지 종류의 통합이 필요하다.

첫 번째는 기업간 협업을 용이하게 하는 가치 네트워크 구현을 위한 수평적 통합, 두 번째는 유연하고 재구성 가능한 제조 시스템을 만들기 위한 공장 내부의 계층적 시스템의 수직적 통합, 마지막으로 세 번째는 제품 맞춤화를

2) Festo AG & Co. KG

지원하기 위한 엔지니어링 통합이다[2].

기업의 수평적 통합과 공장 내부의 수직적 통합은 엔지니어링 통합을 위한 두 가지 기반이며, 이는 제품 수명주기(Product Life Cycle)가 회사 내에서 수행해야 하는 여러 단계로 구성되기 때문이다.

(1) 수평적 통합

한 기업은 다른 많은 관련 기업들과 경쟁하고 협력해야 한다. 공급자, 고객, 파트너, 자회사 등 기업 간의 수평적 통합을 통해 관련 기업은 효율적인 생태계를 형성할 수 있으며, 정보, 금융 및 자료는 이러한 기업들간에 유창하게 흐를 수 있다.

따라서 이를 통해 비즈니스 모델뿐만 아니라 새로운 가치 네트워크가 나타날 수 있다.

또한, 한 기업 안에서도 제품개발, 생산, 구매, 물류, 유지보수, 서비스 등의 각 파트 별 통합을 통해 효율을 높이는 것도 스마트 팩토리의 수평적 통합의 형태이다.

(2) 수직적 통합

공장은 액추에이터 및 센서, 제어, 생산 관리, 제조 및 기업 계획과 같은 여러 가지 물리적 및 정보적 하위 시스템을 소유한다. 유연하고 재구성 가능한 제조 시스템을 구현하려면 ERP (Enterprise Resource Planning) 등 IT Infra 수준까지 다양한 레벨에서 액추에이터 및 센서 신호를 수직 통합해야 한다.

이러한 통합을 통해 스마트 시스템은 다양한 제품 유형에 맞게 동적으로 재구성 될 수 있는 자체 구성 시스템을 형성하며, 생산 공정을 투명하게 만들기 위해 방대한 정보가 수집되고 처리된다.

(3) 엔지니어링 통합

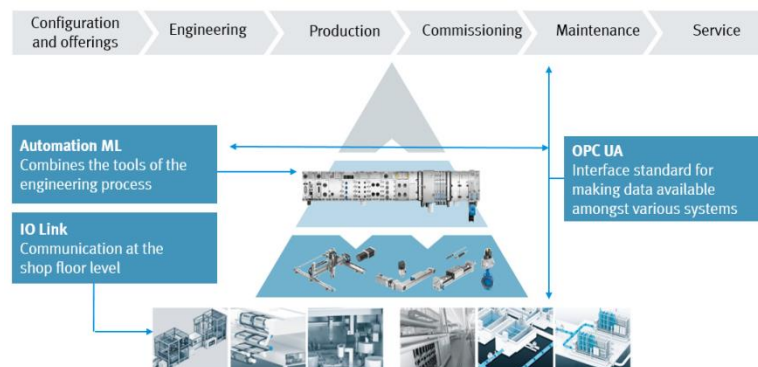
제품 중심의 가치 창출 프로세스에는 고객 요구 사항 표현, 제품 설계 및 개발, 생산 계획, 엔지니어링, 생산, 서비스, 유지 보수 및 재활용과 같은 일련의 활동이 포함된다.

엔지니어링 통합을 통해 지속적이고 일관된 제품 모델을 모든 단계에서 재사용 할 수 있으며, 생산 및 서비스에 대한 제품 설계의 효과는 강력한 소프트웨어 툴 체인을 사용하여 예측할 수 있으므로 고객 맞춤형 제품을 제공할 수 있다.

스마트 팩토리에서 예지보전을 실행하기 위해서는 센서, 액추에이터 등 다양한 설비 내의 데이터를 수집하고 분석하는 수직적 통합이 필수적이며, 수직적 통합을 위한 기술로 OPC-UA, IO-Link 와 같은 표준화 된 프로토콜과 AutomationML 과 같은 공개 표준으로 제공되는 XML 기반의 중립 데이터 형식이 필요하다[그림 3]. 이를 통해 필드 레벨의 센서 데이터를 PLC 등의 상위 컨트롤러를 통해 IT 시스템까지 데이터를 전송할 수 있다.

이는, 기존 제조 공장에서 제조사가 다른 컨트롤러로 구성된 각각의 설비의 데이터를 IT 시스템에 전송하기 위해서는 별도의 Bridge software 등의 개발이

필요했던 것과는 달리, 스마트 팩토리 환경에서는 이 과정이 불필요해지는 것을 의미한다.



[그림 3] Horizontal Integration and Vertical Integration³⁾

2.1.3 스마트 팩토리의 글로벌 트렌드

전 세계적으로 자국의 산업 특성에 맞는 스마트 팩토리의 추진 방향 및 정책을 펼치고 있다. 주요국의 방향 및 정책을 [그림 4]와 같이 정리하였다.

먼저 독일의 경우, 인더스트리 4.0(Industrie 4.0)이라는 정책 아래, 새로운 컨셉의 제조업을 표방하고 있다. 지금까지 독일의 제조기업은 생산성 향상을 위해 생산 기지를 동남아시아, 중국 등 인건비가 저렴한 국가로 이전하는 정책을 펼쳤지만, 해당 국가의 인건비 상승 및 연구 개발 거점과

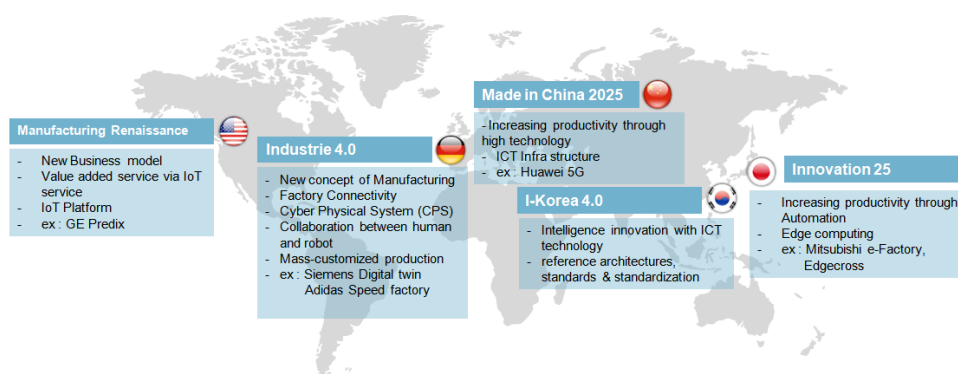
3) Festo AG & Co. KG

생산 거점의 물리적 거리 차이로 인한 협업 부족 등의 문제점이 발생하였다.

이를 해결하기 위한 방법으로 공장과 공장간의 연결, CPS 및 인간과 로봇의 협업을 통한 생산성의 향상을 스마트 팩토리의 중요 방향으로 설정하였고, 스마트 팩토리를 활용한 다품종 대량생산(Mass customization)에 초점을 맞추고 있다.

대표적인 사례가 아디다스(ADIDAS)의 스피드 팩토리(SPEED FACTORY)이다. 스피드 팩토리는 독일의 안스바흐에서 2015 년 시범으로 가동되었고, 기존에 6 주가 소요되던 신발 제작과 배송기간을 5 일로 줄였다. 스피드 팩토리는 CPS 기반의 디지털 트윈(Digital twin) 솔루션과 진보된 자동화 기술을 통해 전통적인 디자인 - 생산 - 유통의 구조를 모바일을 통한 개별 주문과 3D 프린팅을 통한 개별 생산 후, 소비자에게 직접 배송되는 구조로 진행된다.

디지털 트윈을 통해 가상화된 공장에서 시뮬레이션 및 테스트를 통해 지속적인 최적화가 가능하다.



[그림 4] 세계 주요국의 스마트 팩토리 방향 및 정책

미국은 Manufacturing Renaissance 라는 정책 하에 IoT 를 활용한 새로운 비즈니스 모델의 개발에 초점을 맞추고 있다. IoT 를 활용하여 예지보전 모델 플랫폼을 제공하는 GE 의 Predix 가 대표적인 사례이다.

그 외에도 중국의 Made in China 2025, 일본의 Innovation 25 등 세계 여러 나라에서 자국 산업의 특성 및 강점을 바탕으로 스마트 팩토리 정책을 펼치고 있다.

대한민국의 경우, 4 차 산업혁명 위원회, 민관합동 스마트공장추진단, 스마트제조혁신센터를 통해 국내 스마트 팩토리 관련 정책수립, 기반 기술 및 데모공장 구축, 보급사업 및 스마트 팩토리 관련 교육을 통한 인력 양성 등의 사업을 진행하고 있다.

2.2 설비 예지보전

2.2.1 설비종합효율

생산 공정이 기계화, 자동화, 고도화됨에 따라 설비에 대한 의존도가 점점 높아지고 있으며, 설비의 투자 금액이 증가됨에 따라 투자금액의 효과적 관리가 필요하기에 때문에 설비종합효율(Overall Equipment Effectiveness, OEE)의 관리가 점차 중요해지고 있다.

OEE 는 나카지마(Nakajima, 1988)가 Total Productive Maintenance(TPM) 의 일환으로 수행 한 개선 계획의 결과를 평가하기 위한 접근 방법으로 제안하였으며 장비 유효성 평가를 위한 척도로 정의하였다.

따라서 OEE 는 생산 손실 및 생산 비용의 상당 부분을 차지하는 간접적인 숨겨진 비용이 포함된다. 이러한 손실은 가용성 (Availability, A), 성능 (Performance, P) 및 품질 (Quality, Q)과 같이 서로 배타적인 여러 구성 요소의 함수로 공식화 된다[3].

본질적으로 OEE 는 식 (1)과 같이 세 가지 요소를 함께 곱하여 얻은 결과이다.

$$OEE = A \times P \times Q \quad [\text{식 1}]$$

가용성(Availability, A) 요소는 시스템이 작동하지 않는 총 시간을 측정한다.

이 공식에서 로딩 시간>Loading time)은 장비의 총 작동 시간을 나타내며, 계획된 유지 관리, 공식 생산 중단, 프로세스 개선 활동 또는 장비 테스트, 기계에 의해 수행되는 유지 보수, 작업자 교육 등 생산을 방해 할 수 있는 계획된 활동 등을 고려하여 계산된다.

$$A = \frac{\text{Loading time} - \text{downtime}}{\text{Loading time}} \quad [\text{식 2}]$$

두 번째 OEE 요소인 성능(Performance, P)은 이상적인 속도에서 속도 손실, 경미한 정지 및 공회전 등을 고려한 장비의 실제 작동 속도의 비율을 측정한다.

$$P = \frac{\text{Ideal cycle time-output}}{\text{Operating time}} \quad [\text{식 3}]$$

OEE 의 세 번째 요소는 품질(Quality, Q)이다. 이는 총 생산량에 대한 불량 생산의 비율을 나타낸다.

$$Q = \frac{\text{Input-volume of quality defects}}{\text{Input}} \quad [\text{식 4}]$$

이러한 OEE 의 향상을 위해 다양한 활동들이 진행되고 있으며, 그 일환으로 예지보전(Predictive maintenance, PdM)이 주요 주제로 언급되고 있다.

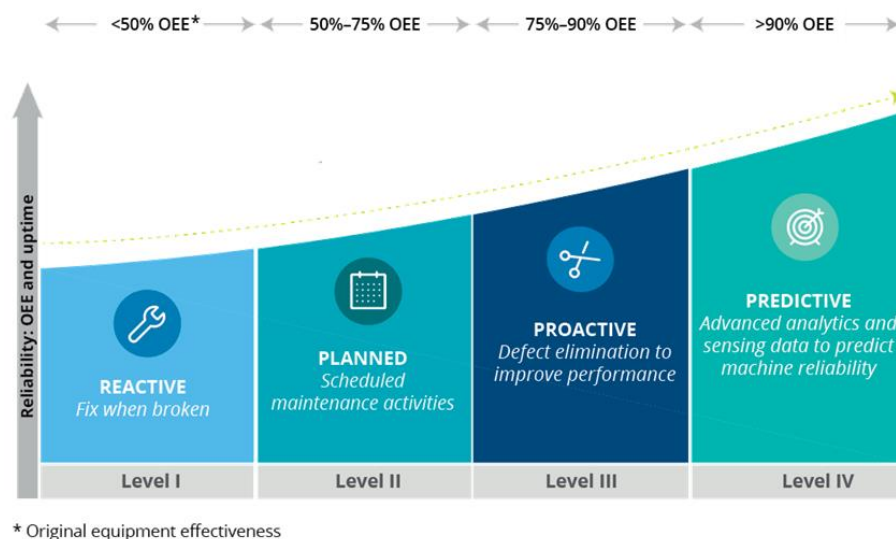
OEE 를 설비의 라이프사이클 관점에서 보면 설비의 취득, 건설, 설치, 시운전부터 설비의 보전(수리, 성능유지, 보수점검 등)과 설비 갱신 및 설비 폐기에 이르기까지 전 과정을 포함하며, 이러한 전사적 설비자산 관리(Enterprise Asset Management)를 위해 여러 학계에서도 수많은 연구성과가 있었으며, 기업체에서의 수많은 실행을 통해 발전 시켜 ISO 55000/55001/55002 로 정리되어 국제표준으로 활용되고 있다.

ISO 55001 은 자산관리를 위한 경영시스템을 위한 요구사항을 정의하기 위해 만들어졌으며, 자산관리 정책, 목표, 프로세스를 통해 조직이 전략적

목표를 달성할 수 있도록 프레임워크를 제공하고 있다. 또한, 비용, 성과, 리스크 관리를 통해 추가 가치를 창출하고 지속적 개선을 추진하기 위해 구조화된, 효과적인, 효율적인 프로세스로도 활용되고 있다.

ISO 55000 과 ISO 55002 는 전체 개요, 원칙, 주요용어 및 적용을 위한 가이드를 제공하여 ISO 55001 을 보완하는 역할을 하고 있다.

OEE 를 향상시키기 위한 방안으로 Deloitte 에서는 예지보전(PdM)으로 OEE 를 90% 이상으로 향상시킬 수 있다고 제시한다[그림 5].



[그림 5] Maintenance strategy continuum⁴⁾

4) Deloitte analysis

2.2.2 예지보전의 정의

앞서 설명한 OEE 를 향상시키기 위해서는 설비가 가장 잘 사용될 수 있는 상태로 유지해야 하며, 이를 달성하기 위해서는 어떠한 유지보수 전략을 가지고 보전활동을 하는지가 중요하다.

유지보수라 함은 대상 시스템을 원래의 기능이 수행될 수 있는 상태로 복구시키는 일련의 활동들의 집합으로 정의할 수 있다[4].

앞서 설명한 [그림 5]을 바탕으로 유지보수의 단계를 구분하면 다음과 같다.

(1) Reactive maintenance

가장 단순한 예지보전의 단계로 고장이 나면 고치는 방식이다. 이 경우, 고장이 발생한 후 조치하여 설비를 재가동 시키기까지 긴 시간이 소요되며, 그로 인해 생산성이 악화되는 문제점이 있다.

Breakdown maintenance 라고도 한다.

(2) Planned maintenance

미리 계획된 일정에 맞게 실시하는 유지보수의 방법이다. 각각의 부품에 대해 과거 고장 이력을 참고하여 고장이 발생하지 않았어도 주기적으로 교체하는 방법이다. Preventive maintenance 라고도 하며, 일정한 시간 주기에 맞춰 하는 경우에는 Time based maintenance(TBM)라고도 한다.

Reactive maintenance 와 비교하여, 유지보수를 위해 고장부위를 파악하여야 하는 시간을 줄일 수 있고, 설비의 가동률을 고려하여 설비가동이

중지하는 일정에 맞춰 유지보수를 할 경우, 전체적인 시간적 효율이 올라가는 장점이 있다. 단, 고장 나지 않은 부품에 대해서도 정해진 주기별로 교체하게 되면 결국 자원의 낭비로 이어지는 문제점이 있다.

(3) Proactive maintenance

설비의 성능 향상을 위해 결함 요소를 미리 제거하는 유지보수 활동이다. 고장이 발생하지 않았더라도 설비의 성능에 악영향을 주는 요소를 찾아내어 사전에 교체를 하는 유지보수 방법이다. 이는 앞서 설명한 Planned maintenance 와 Predictive maintenance 의 중간 단계이다.

(4) Predictive maintenance

설비의 데이터를 분석하여 이상징후를 사전에 파악하고 조치하는 유지보수 방법으로 예지보전이라 한다.

설비의 상태를 기반으로 하기 때문에 Condition based maintenance (CBM)라고도 한다.

이 예지보전은 주기적으로 설비의 상태를 점검하고 그 결과를 진단, 예지하여 수리 여부를 결정하는 방식[5]으로, 스마트 팩토리의 주요 기술 중 하나인 IIoT(Industrial Internet of Things)를 활용하여 다양한 센서 등을 통해 데이터를 수집하여 보전 여부를 결정할 수 있다.

이를 통해 고장 발생 시점을 사전에 예측, 선행 보전활동을 할 수 있기 때문에 기존 유지보수 방식이 가지고 있던 과잉 보전 및 부정확한 고장 분석

등의 문제를 개선하여 보전 활동의 신뢰성을 높이고 경제성을 개선 시킬 수 있다.

예지보전의 장점은 다음과 같이 나열할 수 있다.

- 메인テナンス 비용 감소
- 생산 품질의 개선
- 부품의 재고량 조절 및 교체시기 연장
- 기계류의 수명 연장 및 OEE 향상
- 작업 환경의 안정성 증가
- 에너지 효율화

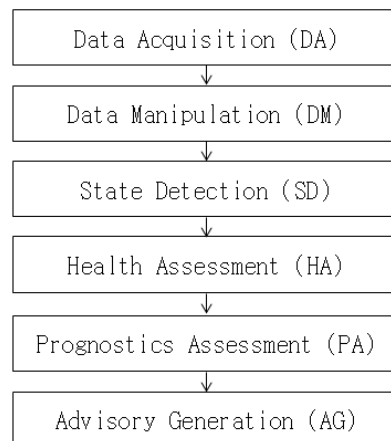
이와 같이 시간이 흘러 감에 따라, 유지보수 방식을 예방하는 차원(Preventive)에서 시작하여, 고장 나기 전에 선행해서(Proactive) 문제의 근원을 없애는 방향을 통해, 고장을 미리 진단하고 예지(Predictive)하여 조치하는 방식으로 변화하고 있다[6].

예지보전은 고장 검출과 진단 뿐만 아니라 상태 모니터링 및 고장 예지까지도 포함하고 있다.

여러 연구에서 예지보전의 절차에 대해 제시하고 있지만, 본 연구에서는 ISO 13374 표준에 기반하여 연구하고자 한다. 기계류 장비의 상태 모니터링 및 진단에 관한 국제표준인 ISO 13374 에서는 예지보전의 절차를 크게 데이터 취득(Data Acquisition, Data Manipulation), 진단(State Detection, Health

Assessment), 예지(Prognostics Assessment), 제시 및 조치(Advisory Generation)로 구분지어 절차를 제시한다[그림 6].

ISO 13374 Condition monitoring and diagnostics of machines



[그림 6] 예지보전 절차⁵⁾

2.2.3 설비 고장 진단과 예지 방법론

본 논문에서는 예지보전의 절차 중 고장의 진단(Diagnostics)과 예지(Prognostics)에 집중하였다.

진단 단계에서는 유지보수 대상 시스템의 이상 징후를 발견 (Detection)한 후, 이상이 있는 부분을 찾고(Isolation) 발견된 이상 징후의 해석 및 원인 확인, 현상에 대해 식별(Identification)을 한다. 따라서, 대상 시스템의

5) ISO 13374

이상 원인에 대한 정확한 파악이 필요하다.

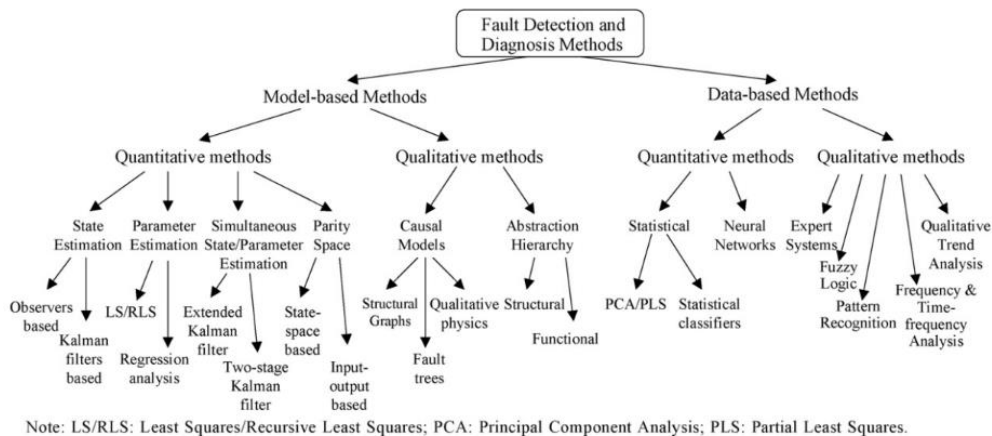
진단과 예지의 가장 큰 차이점은 진단은 과거의 데이터들을 바탕으로 현재의 상태를 분석하지만, 예지는 지금까지의 상태 데이터들을 바탕으로 경향을 분석하여 앞으로 대상 시스템의 고장이 언제쯤 발생할지에 대한 예측과 잔여 수명 및 남은 성능을 예측한다.

진단과 예지의 방법은 주로 Model-based algorithm 과 Data-driven approach 로 구분되며[7], [표 1]과 같은 특징을 가진다.

[표 1] 진단과 예지의 방법 분류 및 특징

분류	설명	특징
Model-based algorithm	특정 시스템의 고장에 대한 물리적인 해석을 통해 모델을 만들어 진단 및 예지를 수행	<ul style="list-style-type: none"> - 비교적 단순하고 직관적 - 모델의 유연성 및 범용성에 한계가 있음 - 개발, 유지보수에 시간과 노력이 필요 - 구체적인 고장 모드 및 현상을 수학 모델로 정립하기 어려움 - 많은 수의 부품을 가지고 있는 시스템에 적용하기 어려움
Data-driven Approach	모델을 직접 코딩하지 않고 과거 데이터로부터 자동으로 생성하여 진단 및 예지를 수행	<ul style="list-style-type: none"> - 유연성 및 범용성이 높음 - 불완전하고 다소 부정확한 데이터에도 적용 가능 - 데이터가 충분히 많이 확보될 경우 좋은 결과를 줄 수 있음 - 확보된 데이터의 양과 품질에 영향을 받음

Model-based algorithm 과 Data-driven approach 에는 각각에 맞는 [그림 7]과 같은 방법론들이 사용된다[14].



[그림 7] Classification of FDD methods⁶⁾

진단 단계에서는 수집되는 데이터를 기반으로 한 통계적 패턴 인식 (Statistical Pattern Recognition), 서포트 벡터 머신(Support Vector Machine), 데이터 마이닝 기법(Decision tree induction), 인공지능 (Fuzzy logic, Neural network)등의 기법이 고장을 진단하는데 주로 사용되고 있다. 예지 단계에서는 회귀 분석 (Regression), 시계열 분석(Time Series Analysis), 신뢰성 이론(Reliability Theory) 기법 등을 이용하여 설비의 수명과 남은 성능을 예측한다. 진단 및 예지를 위해 쓰이는 기법들의 대부분은 데이터가 충분히 확보가 되어야만 좋은 결과를 얻을 수 있다.

6) Y.Zhang, J.Jiang/Annual Reviews in Control 32 (2008) 229-252

특히, 인공지능 기법의 하나인 Neural network 기법은 초기에 다소 부정확하고 불완전한 데이터들이 수집된다고 하더라도 적용이 가능하며, 데이터의 학습을 통해 진단 및 예지의 정확도를 높일 수 있다.

제 3 장 설비 예지보전 모델에 대한 연구

3.1 연구 모형

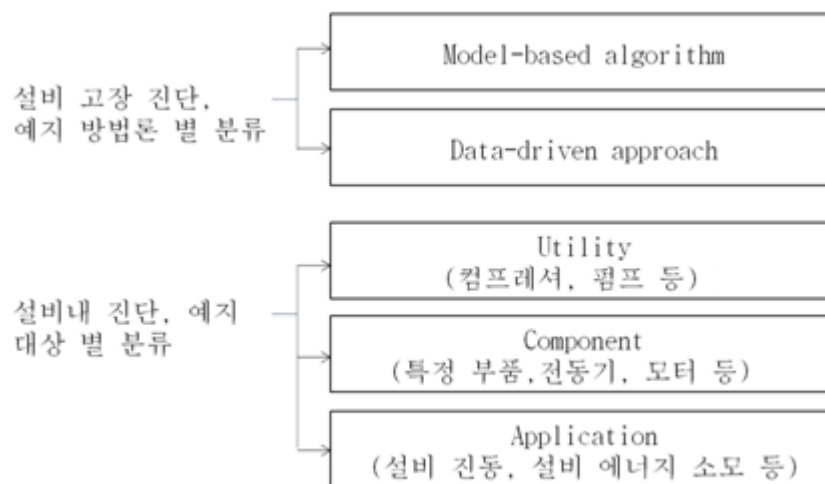
본 연구에서는 기존 문헌 연구의 고찰을 통해 각각의 연구를 설비 고장 진단과 예지에 사용된 방법론과 그 대상에 대해 알아보고 분류를 하여, 연구가 부족한 부분 등의 과제를 도출하고자 하며, 이를 통해 향후 스마트 팩토리 환경에서의 설비 예지보전과 관련된 연구 방향을 제언할 수 있도록 [그림 8]와 같이 연구모형을 설정하였다.



[그림 8] 연구 모형

문헌 고찰 단계에서는 예지보전과 관련된 선행연구에 대해 고찰을 하였으며, 관련 선행연구는 Machine fault, Diagnostics, Prognostics, Predictive maintenance 등의 Key words 를 조합하여 조사하였으며, 최종적으로 설비의 예지보전에 관련된 43 개의 선행연구를 추출하여 고찰을 진행하였다.

고찰을 진행한 43 개의 선행 연구는 [그림 9]과 같이 설비 고장 진단 및 예지 방법론 별로 Model-based algorithm 와 Data-driven approach 로 분류하였으며, 진단 및 예지 대상 별로는 설비를 구동하기 위해 필요한 주변기기인 Utility 와 설비 내에 설치되어 설비를 구성하고 있는 Component, 설비 전체 또는 특정 공정을 수행하는 모듈을 의미하는 Application 으로 구분하였다.



[그림 9] 선행 연구 분류도

고찰을 통해 선행연구의 동향을 분석하고, 연구가 필요하지만 선행연구가 부족한 부분에 대해 파악을 하였으며, 스마트 팩토리과 관련된 산업 고찰을 통해 관련 시장 및 기술 동향과 연계하여 스마트 팩토리 환경에서의 예지보전 연구 방향을 도출하고 실험을 통해 검증하고자 하였다.

3.2 문헌 고찰

3.2.1 설비 고장 진단과 예지 방법론 별 분류

기존 문헌에 사용된 고장 진단 및 예지에 사용된 방법론을 Model-based algorithm 과 Data-driven Approach 로 분류하였다.

Model-based algorithm 에는 Kalman filter[24][38], Particle filter[18][19][20][22], Observer-based method[8][44][46], Control chart[10][33][51] 등의 방법론을 통해 설비의 고장을 진단 및 예지하였다.

반도체 웨이퍼 반송로봇(Wafer Transfer Robot, WTR)의 고장을 예측한 연구에서는 로봇 관절 모터의 펄스 형태의 신호 데이터와 토크 데이터를 활용하였다. 정상상태의 대표파형을 선정 후, UCL(Upper Control Limit)과 LCL(Lower Control Limit)를 활용하여 고장을 예측하였다. 단, 대표파형을 다른 모델의 로봇에는 적용할 수가 없기에 범용성이 떨어지는 한계가 있었다[51].

물류설비 AS/RS 의 Stacker crane 의 고장 진단 연구에서도 UCL, LCL 을 통한 고장을 예측하였다. 설비의 진동, 음향, 온도, 초음파 데이터를 활용하였으며, 예지보전을 위해서는 열화 파라미터의 정기적 또는 자동 측정이 전제조건임을 제시하였다[10].

머시닝 센터의 주축 고장에 대한 연구에서는 Observer-based method 를 사용하여 공장기계 스피들 주축의 진동값 데이터로 상태진단 알고리즘을 개발하였다. 진동 주파수의 분석을 통한 실험으로 실험의 목적이 무고장 보장 실험이었던 관계로 고장 예지와 관련된 연구를 진행되지 못했다[46].

리니어 모터의 고장 진단 연구에서는 리니어 모터 고정자의 저항값 변화 데이터로 Extended Kalman filter 를 사용하였다. 하지만, 고장 진단만을 실시 하였으며, 선형시스템에만 활용할 수 있다는 한계가 있었다[52].

전체적으로 Kalman filter 를 사용한 예지, 진단 연구는 누적 샘플링 에러는 없었으나, 선형시스템과 가우시안 노이즈에만 적용이 가능한 한계가 있었으며, Particle filter 는 비선형 시스템과 비가우시안 노이즈에도 적용 가능하였으나, 파티클 빈곤현상에 따른 누적 샘플링 에러발생과 많은 계산 시간이 소요된다는 한계점이 있었다.

Data-driven approach 에는 Fuzzy logic[12][41][50], Neural network[16][17][23][26][29][38][40][45], Support Vector Machine (SVM) [32][33][39], Pattern recognition [13][35][49][50], Gaussian process regression[21][30] 등의 방법론을 통해 설비의 고장을 진단 및 예지하였다.

모터 펌프의 고장진단을 Data-driven approach 로 접근한 연구에서는 모터의 전류와 진동 데이터로 Chaos 기법을 사용하여 고장을 예측하였다.

하지만, 충분한 데이터를 확보하지 못해 한계가 있었으며, 충분한 데이터를 통한 인공지능 기법의 고장예측 기법을 향후 연구 과제로 선정하였다[47].

설비의 제어 특성에 따른 에너지 소비 패턴을 분석한 연구에서는 설비에서 소모되는 소비전력과 전류 데이터를 활용하여 Data-driven 의 패턴인식 방법론과 Neural network 로 설비의 고장을 진단하였다. Data-driven approach 를 선택한 배경에는 Model-based algorithm 의 경우, Model 을 만들고 분석하는 시간이 오래 걸리며, 설비의 운행 사이클이 변하기 때문에 Model 을 만들기 어려웠기 때문이다. 결과적으로 Neural network 의 경우 데이터가 충분하지 않았을 때 정상을 이상으로 감지하는 경우가 있었고, 규칙 기반의 학습 데이터를 사용했을 때 성능이 좋음을 확인하였다. 단, 다양한 데이터가 확보된 경우에는 Neural network 의 정확도가 더 높음도 알 수 있었다[49].

Fuzzy Logic 과 Pattern Recognition 을 이용하여 설비의 열화 상태를 진단한 연구에서는 적외선 열화상 카메라로 측정한 설비의 온도와 온도 변화량, 전류 패턴을 사용하였다. 기존에 Model-based algorithm 을 활용한 열화상태 진단의 경우, 단순히 열화인지 아닌지를 구분하는 예측 시스템이었으며, 모델에 의존도가 높고, 트렌드 분석이 불가능한 단점이 있었으나 Data-driven approach 를 통해 기존 방법보다 우수함을 확인하였다[50].

유도전동기의 고장을 진단한 연구에서는 전류값을 PCA 와 LDA 를 이용하여 특징벡터를 산출한 후 검증 데이터를 이용하여 각각의 매칭값을 산출하는 방법으로 고장을 진단하였다. 실험에 노이즈가 존재한 경우에는 PCA 가

우수한 성능을 보였으며, 노이즈가 없는 경우는 LDA 가 우수함을 확인하였다. 따라서, 상황에 따라 Data-driven approach 의 방법론을 서로 융합하여 사용하는 것이 효과적임을 알 수 있었다[9].

유도전동기의 고장을 진단한 다른 연구에서는 전류 데이터를 활용하여 다양한 실험을 실시하였다. 특징 추출에 PCA 기법의 진단과 Kernal PCA 와 LDA 기법을 융합한 진단을 비교 실험하였으며, Kernal PCA 와 LDA 를 융합한 실험이 3% 정확도가 높았으며, 고장 인식 결과의 분류 방법에는 Fuzzy C-means 보다 RBF Network(Radial Basis Function Network)를 사용한 것이 0.5% 인식결과가 높았다[12].

복수의 데이터를 활용하여 유도전동기의 고장을 진단한 다른 연구에서는 Decision tree 기법에 전류 데이터와 진동데이터를 함께 사용하였는데, 비교 실험을 통해 전류 데이터만 활용할 때 보다 진동 데이터까지 함께 활용할 때 고장 진단 정확도가 높음을 확인할 수 있었다[11]. 이는 하나의 부품의 고장을 진단할 때 사용되는 데이터의 종류가 많으면 정확도가 높아짐을 의미한다.

전체적으로 Gaussian process regression 은 노이즈가 적은 데이터에서 효과가 있었으며, Neural network 는 비교적 큰 노이즈에도 적용이 가능하였고 모델 형태 구성에 제한이 없었으나, 예지 결과가 네트워크 모델 구축에 의존하며 그에 따라 결과가 달라지는 양상을 보였다.

Model-based algorithm 과 Data-driven approach 의 두 방법론을 모두 사용하여 그 결과를 비교한 선행 연구[53]에서는 고장을 검출하고 이상

부분을 찾아내는 것에 두 방법론 모두 낮은 오감지율을 나타내는 결과를 보여 주었다.

단, Model-based algorithm 의 Observer-based Method 를 사용하였을 때, 선형화 오류뿐 아니라, 모델링 오류로 인해 성능이 제한되었으며, 외란 및 모델링 오류에 민감하였다. Data-driven approach 의 Gaussian Mixture Model 은 복잡한 연산이 필요하고 저장공간을 훨씬 많이 소비하는 특성을 보였다.

두 방법론을 사용한 또 다른 연구[38]에서는 Kalman filter 와 Neural network 를 사용하여 가스 터빈의 성능을 진단을 하였다. 해당 연구에서도 두 방법론 모두 고장을 검출해 내는데 매우 정확한 결과를 보였으나 각각의 장단점은 존재하였다. Neural network 는 본질적으로 비선형이며 모델 정보가 부족하거나 전혀 없는 Application 에서도 사용가능 하였으나, Data-driven approach 이기 때문에 반드시 학습이 필요하였다.

하지만 일단 학습 된 후에는 실시간으로 응용하기에 적합한 수치적으로 빠른 연산자를 제공하였다. Kalman filter 는 Model-based algorithm 으로 선형 모델에서만 적합한 한계가 있었다.

3.2.2 설비 고장 진단과 예지 대상 별 분류

고장 진단, 예지의 기존 연구의 경우, [그림 10]과 같이 그 대상이 유도전동기 및 발전기, 펌프, 컴프레서, 터빈 등 설비 유틸리티 또는 특정 부품이 84% 정도에 해당하였으며, 연구가 이 부분에 치우쳐 있었음을 알 수

있었고, 이러한 제품들이 적용된 공정설비 전체 또는 어플리케이션의 고장에 대한 진단, 예지에 대한 연구는 16%로 매우 부족함을 확인하였다.


이는 어플리케이션 레벨에서는 데이터의 취득이 제한적이며, 취득 대상을 선별하는 것이 어려웠던 것이 이유이다[51].

부품을 대상으로 한 예지보전 연구에서도 모터가 가장 많은 12 건으로 전체의 약 28%를 차지하였고, 모터, 밸브, 인버터 등 주로 전류를 측정하는 대상에 예지보전 연구가 활발함을 알 수 있었다. 전류를 측정할 수 없는 베어링과 같은 부품의 경우 진동, 소리 등의 데이터를 예지보전에 활용하였다.

어플리케이션 대상의 예지보전 연구에는 다양한 부품들의 데이터를 취득할 수 있기 때문에, 전류, 전류 소모량, 토크, 온도, 진동, 속도, 가속도, 초음파, 소리, 각도, 각속도 등 다양한 종류의 데이터들이 활용되었다.

이는 어플리케이션 레벨의 예지보전에는 다양한 부품에서 다양한 유형의 데이터가 활용되며, 이를 통해 고장의 진단, 예지의 정확도를 높일 수 있음을 의미한다.

진단, 예지 대상 별 연구 비중



[그림 10] 진단, 예지 대상 별 연구 비중

3.2.3 설비 고장 진단과 예지 관련 선행 연구 분류

고찰을 진행한 총 43 개의 선행연구를 설비의 고장 진단과 예지 방법론과 대상 별로 [표 2]와 같이 분류하였다.

진단, 예지의 대상 별로 구분하고 상세 대상에서 사용된 데이터의 종류, 사용된 방법론을 기입하였으며, 해당 표를 통해 특정 선행연구로의 접근을 용이하게 하고자 하였다.

[표 2] 선행연구 분류표

Object			Diagnostics & prognostics method	
Unit	Detail	Data	Model-based algorithm	Data-driven approach
Utility	Pump	Vibration[47][24], Temperature[42][43], Flow rate[42], Pressure[24], Current[47]	Kalman filter[24], Rule-based[42][43]	Chaos[47]
	Compressor	Temperature[36][41], Current[41], Vibration[44]	Rule-based[36], Observer based[44]	Fuzzy logic[41], Expert system[41]
	Turbine	Current[37], Angle[37], Temperature[38], Speed[38], Pressure[45], Vibration[39]	Observer-based[37], Kalman filter[38]	Neural network[38][45], SVM[39]
Component	Motor	Vibration[46][22][31][35] [40], Power[23], Voltage[23] Current[48][9][11][12][22]	Observer-based[46] Regression analysis[48] Kalman filter[52]	PCA[9][12], LDA[9][12], Decision tree[11], Fuzzy Logic[12], RBFN[12],

		[31][32],Resistance[52], Sound[13],Speed[22][23], Temperature[23],	Particle filter[22]	Pattern recognition[13][35] Random Forest[31], SVM[32], Neural network[23][40]
	Valve	Current[16][17], Position[16][18],[19], Pressure[16][17], Temperature[17], Velocity[18][19]	Particle filter[18][19]	Neural network[16][17]
	Inverter	Voltage[20][21], Current[20][21], Temperature[21]	Particle filter[20]	Gaussian process regression [21]
	Bearing	Vibration[25][26][27][28] [29][30], Sound[25]	RLS Algorithm[25]	Neural network[26][29] Bayesian Network[27] Support Vector Regression [28] Gaussian process regression [30]
Application	Process machine	Current consumption[49], Current[50], Temperature[50] Vibration[8], Acceleration[8]	Observer-based[8]	Pattern recognition[49][50] Fuzzy Logic[50]
	Robot	Acceleration[33] Torque[51][34],Angle[33], Velocity[33][34], Motor pulse[51], Current[34]	Control chart[51][33], Bond graph model[34]	SVM[33]
	Logistic machine	Vibration, Ultrasonic wave Temperature, Sound, [10]	Control chart[10]	

3.3 과제 도출

기존 문헌의 고찰을 통해 확인한 결과, Model-based algorithm 을 통한 설비의 고장 진단 및 예지에 대한 연구는 특정 모델 및 제품에 특화된 Algorithm 의 사용으로 인해 다른 모델에 확대 적용하기 어려운 문제가 있었음을 알 수 있었으며, Data-driven approach 를 통한 진단, 예지는 데이터의 양만 충분하다면 모델에 의존하지 않고도 Model-based algorithm 을 통한 진단, 예지와 비슷하거나 더 높은 결과를 나타내는 것을 알 수 있었다.

또한, Data-driven approach 을 수행하기 위해서는 충분한 데이터의 저장공간과 복잡한 연산 등을 처리할 수 있는 시스템이 구축이 필요함을 알 수 있었다.

고장 진단, 예지의 대상 별로 선행 연구를 살펴 본 바에 의하면, 그 대상이 모터 및 발전기, 펌프, 컴프레서, 터빈 등 설비 유틸리티 또는 특정 부품 에 치우쳐 있었으며, 이러한 제품들이 적용된 공정설비 전체 또는 어플리케이션의 고장에 대한 진단, 예지에 대한 연구는 부족함을 알 수 있었다.

이는 어플리케이션 레벨에서는 데이터 취득이 제한적이며, 설비 내에서 데이터 취득 대상을 선별하는 것이 어려웠던 것이 이유이다.

하지만, 설비는 수 많은 부품들로 이루어져 있기 때문에 특정 부품 및 유틸리티의 고장 진단 및 예지 만으로는 설비의 예지보전을 실행하기에는

부족하기에 설비 전체 또는 공정 모듈 단위 등 어플리케이션을 대상으로 한 예지보전 연구가 필요함을 알 수 있었다.

3.4 연구방향 제언 및 실험

3.4.1 연구 방향 제언

스마트 팩토리 환경에서는 IoT, Cloud, Big data, Mobile 등의 기술 발달 및 OPC-UA, IO-Link 등의 표준화된 프로토콜을 이용하여 다양한 환경에서 설비의 Data 를 실시간으로 주고 받을 수 있게 되었다.

따라서, 기존에 어플리케이션 레벨에서의 데이터 취득이 제한적이며, 설비 내에서 데이터 취득 대상을 선별하는 것이 어려웠던 한계를 극복할 수 있는 시스템을 구성하는 것이 가능하게 되었기에 다음과 같이 스마트 팩토리 환경에서의 예지보전을 제언하고자 한다.

(1) Data-driven approach 방법론을 활용한 예지보전

예지보전 모델 적용의 용이성, 유연성 및 범용성을 고려하여 Data-driven approach 방법론을 활용한 예지보전이 효과적이다. 이를 통해 동일한 공정 내에 존재하는 다양한 모델의 예지보전에 필요한 시간을 절감할 수 있을 것으로 기대한다.

(2) 어플리케이션 레벨의 예지보전

하나의 어플리케이션은 다양한 부품의 조합들로 이루어져 있다. 기존 연구는 이러한 어플리케이션 내에서 연구자가 임의로 선정한 특정 부품을 대상으로 한 예지보전 연구가 주를 이루었다.

하지만, 설비의 고장은 어느 한 부품에 영향을 받는 경우도 있지만, 주변 부품의 열화를 통한 이상 동작에 영향을 받는 고장도 빈번하다. 따라서, 특정 부품에 대한 예지보전만을 실시하면, 설비 전체에서 발생하는 이상징후를 놓칠 가능성이 있다. 이에, 어플리케이션 레벨에서의 예지보전이 실시되어야 실제 현장에서 활용도가 높아질 것이다.

(3) 의사결정을 위한 최적 데이터 유형 및 규모 연구

앞서 선행 연구 고찰을 통해 알아본 것처럼, Data-driven approach 의 전제 조건은 충분한 양의 데이터 확보이다. 특히, 인공지능 기법인 Artificial Neural network 의 경우는 학습기간에 영향을 많이 받음을 확인하였다. 하지만, 무작정 많은 데이터의 확보하는 것은 데이터 관리 및 분석에 효과적인 방법은 아니다. 따라서, 의사결정을 위한 최적 데이터의 형태, 데이터의 양, 데이터 취득 기간 등과 같은 최적화 연구를 제안한다.

이를 통해 예지보전에 필요한 의사결정 시간 및 정확도를 향상 시킬 수 있을 것으로 기대한다.

(4) 예지보전 대상 선정 연구


데이터 취득을 위해서는 대상 부품에 IoT 센서의 부착이 필요하고, 이를 취득하기 위한 IT 인프라의 확충 등 자본 투자가 필요하다. 따라서, 공장 내의 모든 설비, 모든 부품에 IoT 센서를 부착하여 예지보전을 실시하는 것은 투자 관점에서 비효율적이다.

이에, 예지보전이 필요한 대상의 선정이 필요하며, 선정 고려요인에는 설비의 가격, 설비 가동률, 설비의 유지보수 소요 시간 등과 같이 여러 요인이 있을 것이다.

자본 투자 관점에서 효과적인 예지보전을 위해, 어떤 설비 또는 부품을 예지보전 대상으로 선정할 것인지, 선정에 필요한 고려요인은 어떤 것들이 있는지에 대한 연구를 제안한다.

3.4.2 실험 개요

스마트 팩토리 환경을 구성하기 위해 서로 다른 제조사의 2 개의 PLC 와 협업로봇(Collaborative robot)으로 구성된 테스트 베드를 [그림 11]과 같이 구성하였다.



[그림 11] 테스트 베드 구성

1 번 모듈에는 슈나이더일렉트릭(Schneider electric)의 PLC 와 유니버설 로봇(Universal Robots)의 협업로봇을 설치하였고, 2 번 모듈에는 미쓰비시전기(Mitsubishi electric)와 AUBO 의 협업로봇을 설치하였다.

각각의 협업로봇에서 예지보전에 활용이 가능한 데이터는 [표 3]과 같으며, 이 데이터는 각각의 PLC 에 표준 Ethernet 을 통해 전송되었다.

취득한 데이터는 모두 협업로봇 관절의 서보 모터에서 취득하였으며, 로봇의 제조사마다 제공하는 데이터의 파라미터의 차이는 있었지만, 모두 관절의 각도와 모터의 전류, 온도는 공통적으로 제공하였다.

관절의 각도를 통해 로봇 컨트롤러의 지령 대비 실제 각도를 비교하며 로봇의 이상 징후를 알 수 있으며, 모터의 전류와 온도를 통해 과전류 또는

주변 환경의 변화에 따른 모터의 부하율 증가 등의 진단을 통해 이상 징후를 알 수가 있다.

[표 3] 협업로봇에서 취득한 데이터

모듈 번호	PLC 제조사	로봇 제조사	취득 데이터 (관절의 모터에서 취득)
1	Schneider electric	Universal robots	Angle degree Angle velocity Current Temperature
2	Mitsubishi electric	AUBO	Angle degree Target angle degree Current Target current Voltage Temperature

PLC 를 통해 취득한 협업로봇의 데이터는 PLC 의 OPC-UA Server 기능을 활용하여 OPC-UA 프로토콜을 사용하여 OPC-UA Client 로 전송하였다. OPC-UA Client 는 캡웨어테크놀로지스의 KEPServerEX 를 사용하였다.

또한, 실제 스마트 팩토리 환경에서 활용할 수 있도록 데이터를 Cloud 로 전송하였으며, 협업로봇의 데이터의 최종 취득은 Cloud 를 통해 하였다.

3.4.3 데이터 취득 및 결과

데이터 취득은 1 번 모듈과 2 번 모듈의 PLC 의 제조사가 다르고 협업로봇의 데이터를 취득하기 위해 사용한 내부 프로토콜이 다름에도 불구하고 모두 OPC-UA Server 를 통해 Cloud server 에서 취득이 가능함을 확인하였다.

이는, 스마트 팩토리 환경에서는 제조사가 다른 PLC 가 적용된 설비들로 구성된 설비제조 공장에서도 OPC-UA 프로토콜을 통해 IT 시스템에서 쉽게 데이터를 취득할 수 있는 것이 확인된 것이다.

이전까지 기존 제조 공장에서는 제조사가 다른 PLC 로 구성된 각각의 설비의 데이터를 IT 시스템에 전송하기 위해서는 별도의 Bridge software 등의 개발이 필요했었지만, 스마트 팩토리 환경에서는 이 과정이 불필요해지는 것을 의미한다.

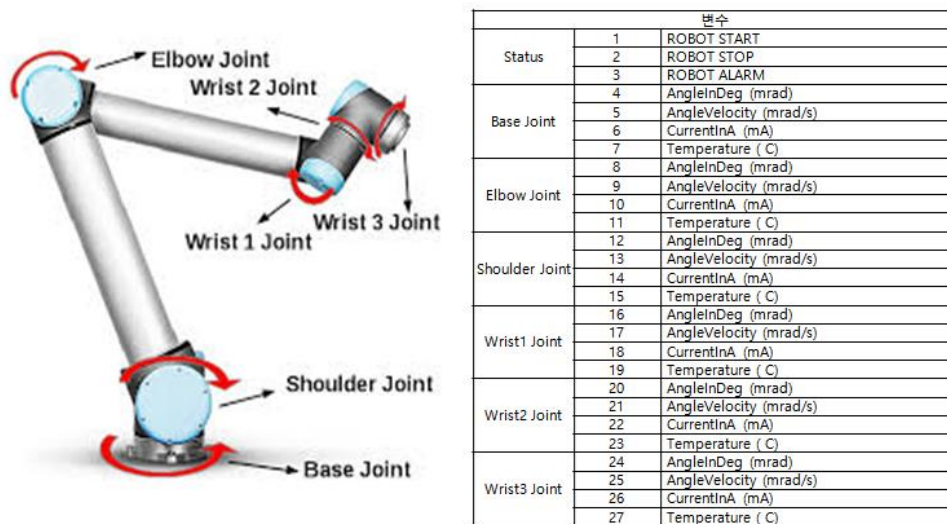
[그림 12]는 가공되지 않은 Cloud server 를 통해 취득한 데이터의 예시이다.

	A	B	C
1	name	time	02.GVL.BaseJointAngleInDeg
2	Test bed02-2018.8	2018-08-01T01:36:24.6712074Z	118.5449905
3	Test bed02-2018.8	2018-08-01T01:36:26.2154513Z	120.1492767
4	Test bed02-2018.8	2018-08-01T01:36:26.4396318Z	121.1233063
5	Test bed02-2018.8	2018-08-01T01:36:27.1071695Z	121.9254456
6	Test bed02-2018.8	2018-08-01T01:36:27.4084122Z	121.8681488
7	Test bed02-2018.8	2018-08-01T01:36:27.5895566Z	121.9254456
8	Test bed02-2018.8	2018-08-01T01:36:28.2360789Z	121.9254456
9	Test bed02-2018.8	2018-08-01T01:36:29.2358842Z	121.9254456
10	Test bed02-2018.8	2018-08-01T01:36:30.2677153Z	121.9254456
11	Test bed02-2018.8	2018-08-01T01:36:31.2384973Z	121.9254456
12	Test bed02-2018.8	2018-08-01T01:36:32.2393034Z	121.9254456
13	Test bed02-2018.8	2018-08-01T01:36:33.2481138Z	121.9254456
14	Test bed02-2018.8	2018-08-01T01:36:34.2389141Z	121.9254456
15	Test bed02-2018.8	2018-08-01T01:36:35.2327146Z	121.9254456
16	Test bed02-2018.8	2018-08-01T01:36:36.2415272Z	121.9254456
17	Test bed02-2018.8	2018-08-01T01:36:37.2433341Z	121.9254456
18	Test bed02-2018.8	2018-08-01T01:36:38.2441403Z	121.9254456

[그림 12] 데이터 취득 예시

데이터의 취득은 8 월 1 일부터 8 월 28 일까지 취득을 하였으며, 데이터 전처리는 1 번 모듈에서만 대표로 진행하였다. 데이터의 전송 주기는 1 초로 설정하였으며, 로봇의 작업 사이클은 16 초였다. 정지구간을 제외하고 로봇의 작업 사이클은 총 30181 회를 취득하였다.

총 6 개의 관절에서 모터의 각도, 각속도, 전류값, 온도 데이터를 24 개의 독립변수로 설정하고, 로봇의 알람 유무를 종속변수로 설정[그림 13]하였으며, 전처리가 완료된 데이터 예시는 [표 4]와 같다.



[그림 13] Universal robots 의 관절 구성 ⁷⁾

[표 4] 가공 데이터 예시

Cycle	Date (YYYY-MM-DD)	Time (HH:MM:SS)	Status			Base joint				Elbow joint			
			ROBOT START	ROBOT STOP	ROBOT ALARM	AngleInDeg (mrad)	AngleVelocity (mrad/s)	CurrentInA (mA)	Temperature (C)	AngleInDeg (mrad)	AngleVelocity (mrad/s)	CurrentInA (mA)	Temperature (C)
1	2018-08-01	01:36:58.373	TRUE	FALSE	FALSE	115.1072388	65395	-0.663999979	46	87.4333725	52	-1.15199995	44
	2018-08-01	01:36:59.373	TRUE	FALSE	FALSE	108.209472	65445	-0.36500001	46	87.0323266	65462	-2.18999982	44
	2018-08-01	01:37:00.365	TRUE	FALSE	FALSE	103.7626801	65473	-0.395000011	46	81.53191376	65392	-2.34699984	44
	2018-08-01	01:37:01.425	TRUE	FALSE	FALSE	101.9292145	0	-0.109999999	46	80.27140608	243	-0.94599998	44
	2018-08-01	01:37:02.373	TRUE	FALSE	FALSE	101.9292145	0	-0.056000002	46	80.2141133	65279	-2.23300004	44
	2018-08-01	01:37:03.365	TRUE	FALSE	FALSE	107.3150177	185	0.460000008	46	79.69844818	75	-0.992999971	44
	2018-08-01	01:37:04.410	TRUE	FALSE	FALSE	118.1439209	49	0.244000003	46	82.10486603	3	-1.24000001	44
	2018-08-01	01:37:05.379	TRUE	FALSE	FALSE	118.430397	0	0.326999992	46	89.55332184	0	-1.603000045	44
	2018-08-01	01:37:06.367	TRUE	FALSE	FALSE	118.3731079	65535	-0.119000003	46	83.79915222	65324	-2.414000034	44
	2018-08-01	01:37:07.372	TRUE	FALSE	FALSE	126.627703	213	0.549000025	46	84.68318176	30	-1.049999957	44
	2018-08-01	01:37:08.365	TRUE	FALSE	FALSE	126.3066864	1	-0.129999993	46	84.91236115	79	-1.383000016	44
	2018-08-01	01:37:09.391	TRUE	FALSE	FALSE	137.2234192	0	0.215000004	46	89.20954895	65490	-1.519999981	44
	2018-08-01	01:37:10.374	TRUE	FALSE	FALSE	132.7543488	65325	-0.717000008	46	85.42802429	11	-1.156999946	44
	2018-08-01	01:37:11.362	TRUE	FALSE	FALSE	120.6076431	65330	-0.749000013	46	84.05293274	65469	-2.243999958	44
	2018-08-01	01:37:12.378	TRUE	FALSE	FALSE	118.5449905	0	-0.25999999	46	90.18357849	0	-1.574000001	44
	2018-08-01	01:37:13.371	TRUE	FALSE	FALSE	118.5449905	65334	-0.231000006	46	88.1209259	65270	-2.177000046	44
2	2018-08-01	01:37:46.379	TRUE	FALSE	FALSE	115.7947998	65385	-0.513000011	46	87.20419312	40	-0.921000004	44
	2018-08-01	01:37:47.393	TRUE	FALSE	FALSE	108.8047104	65438	-0.416999996	46	87.26148987	65490	-2.150000095	44
	2018-08-01	01:37:48.356	TRUE	FALSE	FALSE	104.1064529	65470	-0.361000001	46	82.27675629	65400	-2.262000064	44
	2018-08-01	01:37:49.386	TRUE	FALSE	FALSE	101.9292145	0	-0.219999999	46	79.02089478	255	-1.118999958	44
	2018-08-01	01:37:50.376	TRUE	FALSE	FALSE	101.9292145	0	-0.025	46	81.41732025	65385	-2.062000036	44
	2018-08-01	01:37:51.378	TRUE	FALSE	FALSE	106.3982849	179	0.814000001	46	79.24008179	85	-1.314000001	44
	2018-08-01	01:37:52.376	TRUE	FALSE	FALSE	117.3990784	138	0.414999992	46	82.10486603	2	-1.197000027	44
	2018-08-01	01:37:53.374	TRUE	FALSE	FALSE	118.430397	0	0.275999993	46	89.55332184	0	-1.580000043	44
	2018-08-01	01:37:54.377	TRUE	FALSE	FALSE	118.430397	65332	-0.016000001	46	85.0842514	65262	-2.302000046	44
	2018-08-01	01:37:55.385	TRUE	FALSE	FALSE	125.53508	208	0.549000025	46	84.45400238	42	-1.036000013	44
	2018-08-01	01:37:56.392	TRUE	FALSE	FALSE	137.1088257	26	0.093999997	46	84.79777527	65512	-2.207999940	44
	2018-08-01	01:37:57.388	TRUE	FALSE	FALSE	137.234192	0	0.054000001	46	89.20954895	0	-1.511000037	44
	2018-08-01	01:37:58.381	TRUE	FALSE	FALSE	133.9002686	65322	-0.601000011	46	85.31343842	19	-1.162999988	44
	2018-08-01	01:37:59.377	TRUE	FALSE	FALSE	121.6962585	65334	-0.555999994	46	84.39670563	65478	-2.095999956	44

7) Universal robots

해당 실험을 통해 스마트 팩토리 환경에서는 서로 다른 컨트롤러 및 로봇 등의 어플리케이션이 혼재되어 사용되어도 표준 프로토콜 및 Cloud, IoT 등의 기술을 활용하여 데이터를 쉽게 취득할 수 있음을 확인하였다.

이를 통해 앞서 제안한 Data-driven approach 방법론을 활용한 예지보전, 어플리케이션 레벨에서의 예지보전을 실행 가능함을 증명하였고, 추가로 제안한 예지보전 의사결정을 위한 최적 데이터 유형 및 규모 연구와 예지보전 대상 선정 연구의 전제 조건도 만족함을 알 수 있었다.

제 4 장 결론

4.1 연구 결론

제조업의 트렌드가 스마트 팩토리로 전환됨에 따라 Digitalization 을 통한 새로운 생산 방식 등 생산성을 향상시키기 위한 다양한 시도들이 검토 및 시행되고 있다.

생산성 향상의 일환으로 공장의 주요 자산인 설비의 가용성, 성능, 품질의 종합적인 평가를 통해 생산성을 나타내는데 사용되는 지표인 설비종합효율(OEE, Overall Equipment Effectiveness)을 높이기 위한 여러 방안들이 검토되어 있으며, 이에 대해 본 연구에서는 예지보전 대한 선행 연구 43 건을 고찰 및 분석하였다.

선행 연구의 고찰을 통해 설비의 고장 진단 및 예지를 위한 방법론으로 Model-based algorithm 은 특정 제품에 특화된 모델을 통한 방법으로 다른 제품에 확대 적용하기 어렵다는 문제가 있음을 확인하였고, 충분한 양의 데이터만 확보되면 Data-driven approach 방법론으로 효과적인 진단 및 예지가 가능함을 알 수 있었다. 또한, 인공지능 기법의 경우 초기에 다소 부정확하고 불완전한 데이터들이 수집된다고 하더라도 적용할 수 있으며, 데이터의 학습을 통해 더 정확한 진단 및 예지를 할 수 있음을 알 수 있었다.

지금까지의 Data-driven approach 방법론은 데이터의 취득이 용이한 유도전동기, 발전기, 펌프, 컴프레서, 터빈, 밸브 등과 같은 유틸리티 및 부품에 치중되어 있었지만, 스마트 팩토리 환경에서는 Cloud 및 OPC-UA, IO-Link, AutomationML 과 같은 표준화 기술을 통해 공정설비, 로봇 등의 다양한 어플리케이션 레벨의 데이터의 취득이 용이해지게 되었다.

문헌 고찰을 통해 과제를 선정하였고, 그제 대한 향후 연구 방향으로 기존 연구에서 부족하였던, (1) Data-driven approach 방법론을 활용한 예지보전, (2) 어플리케이션 레벨의 예지보전, (3) 의사결정을 위한 최적 데이터 유형 및 규모 연구, (4) 예지보전 대상 선정 연구에 대해 제언하였다. 또한, 실제로 스마트 팩토리 환경의 테스트 베드를 구성하여 데이터 취득 실험을 하였으며, 이를 통해 제언한 내용이 실제 실행 가능성을 증명하는 과정을 거쳤다.

본 연구를 통해 제언한 내용을 바탕으로 기존 제조 공장이 스마트 팩토리로 전환을 통해 생산성 향상을 높이는데 도움이 되는 후속 연구가 이루어지기를 기대한다.

4.2 연구의 한계

실제 구성한 테스트 베드에서 취득 한 데이터를 바탕으로 Data-driven approach 방법론을 사용하여 예지 모델을 제안하려 하였으나, 취득된 데이터에 고장 관련 데이터의 부족으로 예지보전 모델을 만드는 것은 한계가

있었다. 일부 오동작 데이터가 확보는 되었지만, 오동작에 원인이 실험 대상에 있는지에 대한 판단이 불가능하였다.

이를 통해 스마트 팩토리 환경에서의 효과적인 예지보전을 위해서는 고장항목의 정의 및 체계적인 고장 데이터의 관리가 무엇보다 중요하다는 것을 알 수 있었다. 이에, 진행된 테스트 환경에서 충분한 실험기간 및 고장 관련 데이터를 가지고 Data-driven approach 방법론을 통해 예지보전 모델을 연구하는 것을 향후 연구 과제로 선정하였다.

하지만, 기존 선행 연구 고찰을 통해 향후 스마트 팩토리의 예지보전 연구 방향을 제시한 부분과 서로 다른 컨트롤러를 통해 설비의 데이터를 하나의 프로토콜로 통합하여 데이터 취득이 가능함을 확인하였던 것은 의미 있는 성과로 보여진다.

참 고 문 헌

- [1] Schwab, Klaus. The fourth industrial revolution. *Crown Business*, 2017.
- [2] Wang, Shiyong, Jiafu Wan, Di Li, and Chunhua Zhang. "Implementing smart factory of industrie 4.0: an outlook." *International Journal of Distributed Sensor Networks* 12, no. 1 (2016): 3159805.
- [3] Arturo Garza-Reyes, Jose, Steve Eldridge, Kevin D. Barber, and Horacio Soriano-Meier. "Overall equipment effectiveness (OEE) and process capability (PC) measures: a relationship analysis." *International Journal of Quality & Reliability Management* 27, no. 1 (2010): 48-62.
- [4] 신중호, 전홍배, 김동근. "상태기반 보전 방법에 대한 고찰 및 사례 소개." *Entrue Journal of Information Technology* 13, no. 3 (2014): 123-137.
- [5] Gullledge, Thomas, Scott Hiroshige, and Raj Iyer. "Condition-based maintenance and the product improvement process." *Computers in industry* 61, no. 9 (2010): 813-832.
- [6] Mobley, R. Keith. An introduction to predictive maintenance. *Elsevier*, 2002.
- [7] Poongodai, A., and S. Bhuvaneswari. "Ai technique in diagnostics and prognostics." In *IJCA Proceedings on National Conference on Future Computing*, no. 1, pp. 1-4. 2013.
- [8] 장재호. "종이용기 성형기의 고장진단 및 예지 시스템 개발." *금오공과대학교*, 2018.

- [9] 전병석, 이대중, 이상혁, 유정웅, 전명근. "PCA 와 LDA 에 기반을 둔 융합알고리즘에 의한 유도전동기의 고장진단." *조명·전기설비학회논문지* 19, no. 2 (2005): 152-159.
- [10] 김연수, 신현재. "물류설비 보전관리를 위한 고장 및 진단정보 지원 시스템." *대한설비관리학회지*/9(1) (2004): 27-41.
- [11] 권정민. "전류 및 진동 데이터를 이용한 유도전동기 고장진단에 관한 연구." *울산대학교 일반대학원*, 2006.
- [12] 박장환, 이대중, 전명근. "클러스터링과 방사기저함수 네트워크를 이용한 실시간 유도전동기 고장진단." *조명·전기설비학회논문지*/20(6) (2006): 55-62.
- [13] 조상진, 정의필. "웨이블렛 계수의 분산과 상관도를 이용한 유도전동기의 고장 검출 및 진단." *한국소음진동공학회 논문집*/19(7) (2009): 726-735.
- [14] Zhang, Youmin, and Jin Jiang. "Bibliographical review on reconfigurable fault-tolerant control systems." *Annual reviews in control* 32, no. 2 (2008): 229-252.
- [15] 양재완, 이영두, 구인수. "딥 러닝 및 서포트 벡터 머신기반 센서 고장 검출 기법." *한국인터넷방송통신학회 논문지* 18, no. 2 (2018): 185-195.
- [16] Byington, Carl S., Matthew Watson, and Doug Edwards. "Data-driven Neural network methodology to remaining life predictions for aircraft actuator components." In *Aerospace Conference*, 2004. Proceedings. 2004 IEEE, vol. 6, pp. 3581-3589. IEEE, 2004.
- [17] Macaluso, Andrea. "Prognostic and Health Management System for Hydraulic Servoactuators for Helicopters Main and Tail Rotor." In *Proc.*

- of the European Conference of the Prognostics and Health Management Society*, 2016.
- [18] Daigle, Matthew J., and Kai Goebel. "A model-based prognostics approach applied to pneumatic valves." *International journal of prognostics and health management* 2, no. 2 (2011): 84-99.
- [19] Daigle, Matthew, Chetan S. Kulkarni, and George Gorospe. "Application of model-based prognostics to a pneumatic valves testbed." In *Aerospace Conference*, 2014 IEEE, pp. 1-8. IEEE, 2014.
- [20] Saha, Bhaskar, Jose R. Celaya, Philip F. Wysocki, and Kai F. Goebel. "Towards prognostics for electronics components." In *Aerospace conference*, 2009 IEEE, pp. 1-7. IEEE, 2009.
- [21] Celaya, José R., Abhinav Saxena, Sankalita Saha, Vladislav Vashchenko, and Kai Goebel. "Prognostics of power MOSFET." In *Power Semiconductor Devices and ICs (ISPSD)*, 2011 IEEE 23rd International Symposium on, pp. 160-163. IEEE, 2011.
- [22] Climente-Alarcon, Vicente, Jose Alfonso Antonino-Daviu, Elias G. Strangas, and Martin Riera-Guasp. "Rotor-bar breakage mechanism and prognosis in an induction motor." *IEEE Transactions on Industrial Electronics* 62, no. 3 (2015): 1814-1825.
- [23] Mazhar, M. I., S. Kara, and H. Kaebernick. "Remaining life estimation of used components in consumer products: Life cycle data analysis by Weibull and artificial Neural networks." *Journal of operations management* 25, no. 6 (2007): 1184-1193.

- [24] Gomes, João Paulo P., Bruno P. Leão, Wlamir OL Vianna, Roberto KH Galvão, and Takashi Yoneyama. "Failure prognostics of a hydraulic pump using Kalman filter." In *Annual Conference of the Prognostics and Health Management Society*, 2012.
- [25] Li, Y., S. Billington, C. Zhang, T. Kurfess, S. Danyluk, and S. Liang. "Dynamic prognostic prediction of defect propagation on rolling element bearings." *Tribology transactions* 42, no. 2 (1999): 385-392.
- [26] Huang, Runqing, Lifeng Xi, Xinglin Li, C. Richard Liu, Hai Qiu, and Jay Lee. "Residual life predictions for ball bearings based on self-organizing map and back propagation Neural network methods." *Mechanical systems and signal processing* 21, no. 1 (2007): 193-207.
- [27] Medjaher, Kamal, Diego Alejandro Tobon-Mejia, and Nouredine Zerhouni. "Remaining useful life estimation of critical components with application to bearings." *IEEE Transactions on Reliability* 61, no. 2 (2012): 292-302.
- [28] Loutas, Theodoros H., Dimitrios Roulias, and George Georgoulas. "Remaining useful life estimation in rolling bearings utilizing data-driven probabilistic e-support vectors regression." *IEEE Transactions on Reliability* 62, no. 4 (2013): 821-832.
- [29] Ali, Jaouher Ben, Brigitte Chebel-Morello, Lotfi Saidi, Simon Malinowski, and Farhat Fnaiech. "Accurate bearing remaining useful life prediction based on Weibull distribution and artificial Neural network." *Mechanical Systems and Signal Processing* 56 (2015): 150-172.

- [30] Boškoski, Pavle, Matej Gašperin, Dejan Petelin, and Đani Juričić. "Bearing fault prognostics using Rényi entropy based features and Gaussian process models." *Mechanical Systems and Signal Processing* 52 (2015): 327-337.
- [31] Yang, Bo-Suk, Xiao Di, and Tian Han. "Random forests classifier for machine fault diagnosis." *Journal of mechanical science and technology* 22, no. 9 (2008): 1716-1725.
- [32] Widodo, Achmad, and Bo-Suk Yang. "Wavelet support vector machine for induction machine fault diagnosis based on transient current signal." *Expert Systems with Applications* 35, no. 1-2 (2008): 307-316.
- [33] Caccavale, F., P. Cilibrizzi, F. Pierri, and L. Villani. "Actuators fault diagnosis for robot manipulators with uncertain model." *Control Engineering Practice* 17, no. 1 (2009): 146-157.
- [34] Chatti, Nizar, Remy Guyonneau, Laurent Hardouin, Sylvain Verron, and Sebastien Lagrange. "Model-based approach for fault diagnosis using set-membership formulation." *Engineering Applications of Artificial Intelligence* 55 (2016): 307-319.
- [35] Bittencourt, André Carvalho, Kari Saarinen, Shiva Sander-Tavallaey, Svante Gunnarsson, and Mikael Norrlöf. "A data-driven approach to diagnostics of repetitive processes in the distribution domain-applications to gearbox diagnostics in industrial robots and rotating machines." *Mechatronics* 24, no. 8 (2014): 1032-1041.

- [36] Rossi, Todd M., and James E. Braun. "A statistical, rule-based fault detection and diagnostic method for vapor compression air conditioners." *Hvac&R Research* 3, no. 1 (1997): 19-37.
- [37] Travé-Massuyès, Louise, and Robert Milne. "Gas-turbine condition monitoring using qualitative model-based diagnosis." *IEEE Expert* 12, no. 3 (1997): 22-31.
- [38] Volponi, Allan J., Hans DePold, Ranjan Ganguli, and Chen Daguang. "The use of Kalman filter and Neural network methodologies in gas turbine performance diagnostics: a comparative study." *Journal of engineering for gas turbines and power* 125, no. 4 (2003): 917-924.
- [39] 안병현, 유현탁, 최병근. "가스터빈 고장 진단을 위한 기계 학습과 유전 알고리즘을 이용한 특징 분석." *한국정밀공학회지* 35, no. 2 (2018): 163-167.
- [40] Roemer, Michael J., Chi-an Hong, and Stephen H. Hesler. "Machine health monitoring and life management using finite element based Neural networks." In *ASME 1995 International Gas Turbine and Aeroengine Congress and Exposition*, pp. V005T14A019-V005T14A019. American Society of Mechanical Engineers, 1995.
- [41] 임상돈, 정영득, 김종래. "효율적인 공기압축기 운영을 위한 이상진단모델 연구." *대한안전경영과학회지* 16, no. 3 (2014): 239-248.
- [42] 한용희, 이일환, 김민수. "3 실형 멀티 열펌프 시스템의 고장감지 및 진단에 관한 연구." *대한기계학회 춘추학술대회* (2008): 154-156.
- [43] 이재승, 조진민, 김용진, 김민수. "이산화탄소 열펌프 시스템의 고장감지 및 진단에 관한 연구." *대한기계학회 춘추학술대회* (2008): 161-163.

- [44] 이정환, 김병수, 구동식, 김효중, 최병근. "공기압축기의 진동분석 및 진단." *한국소음진동공학회 학술대회논문집* (2008): 984-989.
- [45] 이종준, 윤재은, 김동섭. "신경회로망 기법에 기반한 마이크로터빈 성능진단 기법의 검증." *유체기계 연구개발 발표회 논문집* (2006): 275-280.
- [46] 이태홍. "머시닝센터 주축 고장예측에 관한 연구." *한국기계가공학회지* 15, no. 4 (2016): 134-140.
- [47] 정연옥. "모터 · 펌프의 고장진단에 관한 연구." *전남대학교*, 2016.
- [48] 백상훈. "모델기반 선형 구동기 고장 진단." *한양대학교 대학원*, 2012.
- [49] 김남훈. "설비이상을 탐지하기 위한 제어 특성에 대한 효율적인 에너지소비 패턴분석." *아주대학교*, 2017.
- [50] 최우용. "퍼지 추론 알고리즘을 이용한 실시간 열화 및 고장진단 시스템에 대한 연구." *수원대학교*, 2015.
- [51] 조성민. "반도체 웨이퍼 반송 로봇의 고장 예측 방법." *성균관대학교 일반대학원*, 2013.
- [52] 안성국. "영구자석 동기전동기 드라이브의 확장형 칼만필터를 이용한 개방성 고장진단 기법." *한양대학교 대학원*, 2011.
- [53] Yang, Ruochen, and Giorgio Rizzoni. "Comparison of Model-based Vs. Data-driven Methods for Fault Detection and Isolation in Engine Idle Speed Control System." *Annual Conference of The Prognostics and Health Management Society*, 2016.

[Abstract]

Analysis and Suggestion of Predictive Maintenance Models for Smart Factory

Kang, Soungwoo

Major in Industrial Information Management

The Graduate School of Engineering

Yonsei University

Supervised by Prof. Kim, Chang Ouk

Many countries in the world are increasing their interest and policy support for smart factories in order to improve their manufacturing competitiveness. There are many things that existing manufacturing factories want to gain from the conversion to Smart Factory, but the common purpose is to improve productivity and manufacturing competitiveness.

In order to increase productivity and manufacturing competitiveness, each company is considering the smart factory and predictive maintenance.

Predictive Maintenance (PdM) is which analyzes machine data to identify abnormal signs in advance and implements them as a way to increase overall equipment efficiency (OEE) of factories.

Although many studies related to predictive maintenance have been researched in the past, there have been many limitations due to the lack of a proper environment for obtaining the status information of facilities.

In this paper, I analyzed the level of smart factory technology related to predictive maintenance and suggested a study on the diagnosis and prognosis of equipment fault in smart factory environment through review of 43 case literatures.

I confirmed the possibility of using suggestions through a experiment that collect data that can be used for maintenance of facilities in a real smart factory environment. And through this experiment, the definition of the fault item and the management of the systematic fault data were found to be important for the predictive maintenance.

Key words : Smart factory, Predictive maintenance (PdM), Condition based maintenance (CBM), Overall Equipment Effectiveness, Data-driven approach, Model-based algorithm